

ScratchMath Homework Feedback Agent 实现方案

1. 项目定位

项目名称：ScratchMath Homework Feedback Agent

项目目标：构建一个面向学生手写数学草稿的作业反馈 Agent，完成以下任务：

- 识别学生错误类型
- 生成错误原因解释
- 生成个性化反馈建议
- 汇总班级级别的错误模式，并进行网络分析与可视化

该方向与课程要求一致：项目需要以 **Agent + 多个独立 Skill** 的形式实现，每个成员负责一个可独立测试的 Skill，最终由 Agent 统一编排。课程还要求系统具备明确 workflow、可量化评测、分析和可视化。来源：课程项目说明 PDF；ScratchMath 官方仓库 README。

2. 为什么选 ScratchMath

ScratchMath 非常适合做“**手写数学作业错误诊断与反馈**”类项目，而不适合直接做“完整 OCR + 总分判分器”。

2.1 数据集特点

ScratchMath 提供两类核心任务：

- **ECE (Error Cause Explanation)**：生成错误原因解释
- **ECC (Error Cause Classification)**：将错误分为 7 类

2.2 数据字段

每个样本包含：

- question_id
- question
- answer
- solution
- student_answer
- student_scratchwork (图像)
- error_category
- error_explanation

2.3 数据规模

- `primary`: 1479 条
- `middle`: 241 条
- 总计: 1720 条

2.4 适合做什么

适合:

- 错误类别识别
- 错误解释生成
- 个体反馈生成
- 班级错误模式分析

不适合直接当主任务:

- 高精度 OCR benchmark
- 整体分数预测
- 完整步骤级自动阅卷

核心判断: 将“识别”作为中间 Skill, 把“错误诊断 + 反馈生成 + 班级分析”作为主线, 是最稳妥的设计。

3. 最终项目题目建议

ScratchMath-Feedback Agent: Handwritten Math Error Diagnosis and Class-Level Error Network Analysis

输入

- 题目 `question`
- 正确答案 `answer`
- 参考解法 `solution`
- 学生最终答案 `student_answer`
- 学生手写草稿图 `student_scratchwork`

输出

- 预测错误类别
 - 错误原因解释
 - 面向学生的反馈建议
 - 面向教师的班级分析 dashboard
-

4. 系统总体架构

项目采用 **Agent + 5 个 Skills + 共享数据层** 的结构。

Agent 的职责

Agent 不直接做识别或分析，而是负责：

1. 接收用户请求或批量作业输入
2. 决定调用哪些 Skills
3. 串联中间结果
4. 输出学生端反馈和教师端分析结果

推荐工作流

1. 读取样本
 2. 解析手写草稿
 3. 分类错误类型
 4. 解释错误原因
 5. 生成学生反馈
 6. 汇总班级结果并做错误网络分析
-

5. 五个 Skill 的详细设计

Skill 1: Handwritten Parsing Skill

功能

- 读取 `student_scratchwork`
- 做基础图像解析、区域切分、轻量 OCR/公式识别
- 产出结构化中间表示，供后续错误分析使用

输入

- `question`
- `student_scratchwork`

输出

- `regions`
- `ocr_tokens`
- `formula_lines`
- `visual_features`
- `parse_confidence`

说明

ScratchMath 没有完整 OCR 真值，因此本 Skill 不应被定义为“单独追求 OCR SOTA”，而应被定义为“为下游错误诊断提供结构化视觉证据”。

可独立测试内容

- 是否能正确加载图像
 - 是否能输出稳定的区域划分结果
 - 是否能提取关键公式/关键步骤候选
-

Skill 2: Error Classification Skill

功能

根据图像和文本上下文，预测错误类别。

输入

- question
- answer
- solution
- student_answer
- student_scratchwork
- 可选：Skill 1 输出

输出

- pred_error_category
- category_probs
- evidence_regions

目标标签

7 类错误：

- 计算错误
- 题目理解错误
- 知识点错误
- 答题技巧错误
- 手写誊抄错误
- 逻辑推理错误
- 注意力与细节错误

可独立测试内容

- 分类准确率
 - confusion matrix
 - 是否能给出高置信度区域证据
-

Skill 3: Error Explanation Skill

功能

生成自然语言错误解释，说明学生错在哪里、为什么错。

输入

- question
- answer
- solution
- student_answer
- student_scratchwork
- 可选: Skill 1 / Skill 2 输出

输出

- pred_error_explanation
- evidence_spans
- repair_hint

可独立测试内容

- 与 gold explanation 的一致性
 - LLM-as-a-Judge 分数
 - 人工评价: 具体性、正确性、可教性
-

Skill 4: Feedback Generation Skill

功能

把分类与解释结果转成学生可读的反馈。

输出建议固定为三段

1. 你错在什么地方
2. 正确的解题思路是什么
3. 下次如何避免类似错误

输出

- student_feedback
- next_step_advice
- teacher_summary

可独立测试内容

- 反馈是否具体
 - 是否包含可执行建议
 - 语言是否清晰、建设性
-

Skill 5: Class Analytics & Error Network Skill

功能

汇总全班样本结果，构建图结构并做可视化分析。

建议构建的 3 张图

1. 学生—错误类型二部图

- 学生节点
- 错误类型节点
- 学生出现某类错误则连边

2. 错误共现图

- 节点：错误类型
- 边：两类错误经常在同一学生/同一题型中共同出现

3. 学生相似图

- 基于错误类别分布、解释 embedding、题型表现建立边
- 用于聚类 and 社区发现

输出

- 高频错误分布
- 错误社区
- 学生群体画像
- 班级 dashboard 图表

可独立测试内容

- 图构建正确性
 - 社区划分稳定性
 - 可视化可解释性
-

6. 共享数据结构设计

建议先统一 schema，再做分工实现。

6.1 SampleRecord

```
{
  "sample_id": "...",
  "subset": "primary",
  "question": "...",
  "answer": "...",
  "solution": "...",
  "student_answer": "...",
  "student_scratchwork_path": "...",
  "gold_error_category": "...",
  "gold_error_explanation": "..."
}
```

6.2 ParseRecord

```
{
  "sample_id": "...",
  "ocr_lines": [],
  "detected_regions": [],
  "formula_candidates": [],
  "parse_confidence": 0.84
}
```

6.3 DiagnosisRecord

```
{
  "sample_id": "...",
  "pred_error_category": "计算错误",
  "category_probs": {
    "计算错误": 0.71,
    "知识点错误": 0.12
  },
  "pred_error_explanation": "...",
  "evidence_regions": [2, 5]
}
```

6.4 FeedbackRecord

```
{
  "sample_id": "...",
  "student_feedback": "...",
  "next_step_advice": "...",
  "teacher_summary": "..."
}
```

7. 建模方案

7.1 Baseline

使用现成多模态模型直接做 ECC / ECE:

- 输入: 图像 + question + answer + solution + student_answer
- 先复现 ScratchMath 官方评测流程

Baseline 价值

- 快速跑通任务
- 拿到可比较基线
- 为后续增强做对照

7.2 主方法

方法名建议

Structured Scratchwork Grounding

核心思想

先将草稿图解析成更结构化的中间证据, 再做错误分类和错误解释。

两阶段流程

Stage 1: 草稿结构解析

- 区域切分
- 关键步骤抽取
- 轻量 OCR / 公式候选生成

Stage 2: 诊断与反馈

将以下信息输入模型:

- question

- `answer`
- `solution`
- `student_answer`
- `student_scratchwork`
- `parsed_scratchwork`

预期优势

- 比端到端看整张图更稳定
 - 更容易给出可解释证据
 - 对细粒度错误类别更有帮助
-

7.3 可选增强

- 多任务学习：ECC + ECE 联合训练
 - 区域注意力/关键步骤定位
 - retrieval-based feedback 模块
-

8. 数据划分与实验设置

建议

不要简单随机切分。

推荐划分方式

- 按 `error_category` 分层
- 按 `question` 分组，避免相同题目泄漏
- 采用：
 - 70 / 15 / 15 划分，或
 - 5-fold cross validation

结果建议分别报告

- `primary`
 - `middle`
 - `overall`
-

9. 评测指标设计

9.1 ECC（错误分类）

- Weighted Accuracy
- Macro F1
- Confusion Matrix

9.2 ECE（错误解释）

- LLM-as-a-Judge
- BERTScore
- 人工评估（正确性 / 具体性 / 可教性）

9.3 Feedback 质量

人工打分：

- 是否指出具体错误
- 是否给出可执行建议
- 是否语言建设性

9.4 班级网络分析

- 高频错误占比
- 错误共现边强度
- 学生社区数量
- 社区质量指标（如 silhouette / purity）

10. OCR 没有真值时如何处理

这是项目里必须主动说明的点。

结论

不要把 OCR 本身当成主结果。

正确做法

把 OCR/解析作为中间变量，比较它是否提升下游 ECC/ECE。

设计两组实验

1. 不加解析：直接图像 + 文本输入
2. 加解析：图像 + 文本 + structured parse

如果想额外评 OCR

可以人工补一个小测试集：

- 抽 100–200 张样本

- 只标关键中间步骤
 - 用于评估关键步骤识别质量
-

11. 消融实验设计

建议至少做 4 个：

1. Text-only

- 只用 `question + answer + solution + student_answer`

2. Image-only

- 只用 `student_scratchwork`

3. Image + Text

- 基础多模态输入

4. Image + Text + Structured Parse

- 主方法

可选再加两个

5. 无 solution

6. 无 student_answer

预期结论

- 只看文本不够，因为看不到过程性错误
 - 只看图像不够，因为缺题目上下文
 - `solution` 和 `student_answer` 都很重要
 - 结构化解析能提升稳定性和可解释性
-

12. 如何体现“Homework Feedback Agent”而不只是 benchmark 跑分

最终 demo 应该同时提供两端输出。

学生端

- 预测错误类型
- 错误解释
- 改进建议

教师端

- 各错误类型占比
- 哪些错误最常共现
- 哪类学生群体最容易在哪些题型上出错

这一步是把 ScratchMath benchmark 提升为课程项目 Agent 的关键。

13. 4 周实施排期

第 1 周：数据与 baseline

- 下载并清洗 ScratchMath
- 跑通官方 ECC / ECE 脚本
- 统一 schema
- 做数据统计与初步可视化

第 2 周：核心诊断 Skill

- 完成 Error Classification Skill
- 完成 Error Explanation Skill
- 跑第一版实验

第 3 周：解析 Skill 与 Agent 集成

- 完成 Handwritten Parsing Skill
- 完成 structured parse 实验
- 接入 Feedback Generation Skill

第 4 周：班级分析与写作

- 完成 Class Analytics & Error Network Skill
- 做 dashboard
- 做 ablation 和 case study
- 写 group report 和 individual reports

14. 报告写作建议

课程报告要求包括：

- Functionality
- References
- Results
- Analysis

- Visualization

Group Report（4 页）建议结构

1. Introduction
2. Agent Overview
3. Skill Design
4. Experiments
5. Analysis
6. Visualization

Individual Report（每人 3 页）建议结构

1. Skill 定义
2. 方法实现
3. 独立实验
4. 与 Agent 的交互
5. 局限与改进

15. 最终创新点建议

创新点 1

从“只看最终答案”升级到“结合草稿过程进行错误诊断”。

创新点 2

通过 **Structured Scratchwork Grounding**，增强错误分类和解释的稳定性与可解释性。

创新点 3

把个体错误诊断扩展到班级级错误网络分析，更贴合 social network analysis 课程定位。

16. 最小可行版本（MVP）

如果时间紧，建议先完成以下版本：

- Skill 1: Error Classification
- Skill 2: Error Explanation
- Skill 3: Feedback Generation
- Skill 4: Error Network Analytics
- Agent: 统一调度

此时 Handwritten Parsing Skill 只做轻量辅助，不强求完整 OCR。

17. 一句话结论

ScratchMath 最适合做“手写数学作业错误诊断与反馈 Agent”，不适合直接做“完整 OCR + 总分判分系统”。

最佳方案是：

- 把“识别/解析”当中间 Skill
- 把“错误分类 + 错误解释”当主任务
- 把“反馈生成 + 班级错误网络分析”当项目亮点

这样既能充分利用 ScratchMath 的监督信号，也能满足课程对 Agent、Skill、评测、分析和可视化的要求。

18. 参考来源

- 课程要求： `FinalProjectGuidance.pdf`
- ScratchMath 官方仓库 README： `ai-for-edu/ScratchMath`
- ScratchMath Hugging Face 数据集页： `songdj/ScratchMath`